Python Niveau I

Projet intégrateur — Python Niveau I

Analyse des pourboires dans un restaurant

Durée : 1h45 **Dataset** : tips (via seaborn) **Livrable** : un script `.py` commenté

Contexte

Vous êtes analyste de données dans une chaine de restaurants. La direction vous demande d'analyser les pourboires pour mieux comprendre le comportement des clients et optimiser le service.

Dataset

```
import seaborn as sns
tips = sns.load_dataset("tips")
```

Colonne	Description	Type
`total_bill`	Montant de l'addition ($)	float64
`tip`	Montant du pourboire ($)	float64
`sex`	Sexe du payeur	category
`smoker`	Fumeur (Yes/No)	category
`day`	Jour de la semaine	category
`time`	Moment (Lunch/Dinner)	category
`size`	Taille de la table (personnes)	int64

Étape 1 : Import et exploration (20 min)

1. Importez les librairies nécessaires (`pandas`, `numpy`, `matplotlib.pyplot`, `seaborn`)
2. Chargez le dataset avec `sns.load_dataset("tips")`
3. Affichez les 5 premières et 5 dernières lignes
4. Affichez les dimensions avec `shape`
5. Affichez les types de colonnes avec `dtypes`
6. Utilisez `info()` pour vérifier les valeurs manquantes
7. Affichez les statistiques descriptives avec `describe()`
8. Affichez les valeurs uniques des colonnes catégoriques

Étape 2 : Nettoyage et préparation (15 min)

1. Créez une colonne `tip_pct` = pourboire en pourcentage de l'addition
2. Créez une colonne `bill_cat` catégorisant les additions :
   - `"Petit"` si total_bill < 15
   - `"Moyen"` si 15 <= total_bill < 30
   - `"Gros"` si total_bill >= 30
3. Traduisez la colonne `day` en français avec `map()`
4. Vérifiez les types de vos nouvelles colonnes

Étape 3 : Statistiques descriptives (20 min)

1. Calculez le pourboire moyen par jour
2. Calculez le pourboire moyen par sexe
3. Calculez le pourboire moyen par jour ET moment (Lunch/Dinner)
4. Calculez la corrélation entre `total_bill` et `tip`
5. Créez un tableau croisé (`pd.crosstab`) : jour x fumeur/non-fumeur

Étape 4 : Visualisations (30 min)

Créez un dashboard de 4 graphiques avec `fig, axes = plt.subplots(2, 2, figsize=(14, 10))` :

1. **Scatter** (haut-gauche) : `total_bill` vs `tip`, coloré par `sex`, avec droite de régression
2. **Histogramme** (haut-droite) : distribution de `tip_pct`, avec lignes pour moyenne et médiane
3. **Boxplot** (bas-gauche) : `tip` par `day`
4. **Barplot** (bas-droite) : pourboire moyen par jour et moment (barplot groupé)

Ajoutez un titre global avec `fig.suptitle()`. Exportez en PNG avec `plt.savefig("dashboard_tips.png", dpi=200)`.

Étape 5 : Synthèse (20 min)

Écrivez 5 conclusions en commentaires dans votre script. Exemples de questions à adresser :

- Quel jour génère les pourboires les plus généreux ?
- Y a-t-il une différence significative entre hommes et femmes ?
- Les fumeurs sont-ils plus ou moins généreux ?
- Quelle est la relation entre le montant de l'addition et le pourboire ?
- Le moment (déjeuner/dîner) influence-t-il le pourboire ?

Barème

Critère	Points
Import et exploration correcte	15
Nettoyage et colonnes calculées	15
Statistiques descriptives	20
Dashboard 4 graphiques	30
Conclusions pertinentes	10

Critère	Points
Qualité du code et commentaires	10
Total	**100**

Solution complète

```
# ============================================================
# Projet integrateur – Analyse des pourboires
# Python Niveau I
# ============================================================

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# ------------------------------------------------------------
# Etape 1 : Import et exploration
# ------------------------------------------------------------

tips = sns.load_dataset("tips")

print("=== EXPLORATION ===")
print(f"Dimensions : {tips.shape[0]} lignes x {tips.shape[1]} colonnes\n")

print("--- Premieres lignes ---")
print(tips.head())

print("\n--- Dernieres lignes ---")
print(tips.tail())

print("\n--- Info ---")
tips.info()

print("\n--- Statistiques ---")
print(tips.describe())

print("\n--- Valeurs uniques ---")
for col in tips.select_dtypes(include="category").columns:
    print(f"  {col} : {tips[col].unique().tolist()}")

# ------------------------------------------------------------
# Etape 2 : Nettoyage et preparation
```

```
# ------------------------------------------------------------

print("\n=== NETTOYAGE ===")

# Pourcentage de pourboire
tips["tip_pct"] = (tips["tip"] / tips["total_bill"] * 100).round(1)

# Categorisation des additions
def categoriser_bill(montant):
    if montant < 15:
        return "Petit"
    elif montant < 30:
        return "Moyen"
    else:
        return "Gros"

tips["bill_cat"] = tips["total_bill"].apply(categoriser_bill)

# Traduction des jours
jours_fr = {"Sun": "Dimanche", "Sat": "Samedi", "Thur": "Jeudi", "Fri": "Ve
tips["jour_fr"] = tips["day"].map(jours_fr)

print(tips[["total_bill", "tip", "tip_pct", "bill_cat", "jour_fr"]].head(10
print(f"\nRepartition bill_cat :\n{tips['bill_cat'].value_counts()}")

# ------------------------------------------------------------
# Etape 3 : Statistiques descriptives
# ------------------------------------------------------------

print("\n=== STATISTIQUES ===")

# Pourboire moyen par jour
print("--- Tip moyen par jour ---")
print(tips.groupby("jour_fr")["tip"].mean().round(2))

# Pourboire moyen par sexe
print("\n--- Tip moyen par sexe ---")
print(tips.groupby("sex")["tip"].mean().round(2))

# Pourboire moyen par jour et moment
print("\n--- Tip moyen par jour + moment ---")
print(tips.groupby(["jour_fr", "time"])["tip"].mean().round(2))

# Correlation
corr = tips["total_bill"].corr(tips["tip"])
print(f"\nCorrelation total_bill / tip : {corr:.4f}")

# Tableau croise
print("\n--- Crosstab jour x fumeur ---")
```

```
ct = pd.crosstab(tips["jour_fr"], tips["smoker"], margins=True)
print(ct)

# ------------------------------------------------------------
# Etape 4 : Visualisations
# ------------------------------------------------------------

fig, axes = plt.subplots(2, 2, figsize=(14, 10))
fig.suptitle("Analyse des pourboires — Restaurant", fontsize=16, fontweight

# 1. Scatter : total_bill vs tip
ax = axes[0, 0]
couleurs_sex = {"Male": "#2196F3", "Female": "#E91E63"}
for sexe, grp in tips.groupby("sex"):
    ax.scatter(grp["total_bill"], grp["tip"], c=couleurs_sex[sexe],
               alpha=0.6, label=sexe, edgecolors="white", linewidth=0.5)

coeffs = np.polyfit(tips["total_bill"], tips["tip"], 1)
x_line = np.linspace(0, 55, 100)
ax.plot(x_line, np.poly1d(coeffs)(x_line), "k--", linewidth=1.5, label="Reg
ax.set_xlabel("Addition ($)")
ax.set_ylabel("Pourboire ($)")
ax.set_title("Addition vs Pourboire")
ax.legend(fontsize=9)

# 2. Histogramme : distribution de tip_pct
ax = axes[0, 1]
ax.hist(tips["tip_pct"], bins=25, color="#66BB6A", edgecolor="white", alpha
moy_pct = tips["tip_pct"].mean()
med_pct = tips["tip_pct"].median()
ax.axvline(moy_pct, color="red", linestyle="--", linewidth=2,
           label=f"Moyenne : {moy_pct:.1f}%")
ax.axvline(med_pct, color="blue", linestyle="-.", linewidth=2,
           label=f"Mediane : {med_pct:.1f}%")
ax.set_xlabel("Pourboire (%)")
ax.set_ylabel("Frequence")
ax.set_title("Distribution du % de pourboire")
ax.legend(fontsize=9)

# 3. Boxplot : tip par jour
ax = axes[1, 0]
jours_ordre = ["Thur", "Fri", "Sat", "Sun"]
data_box = [tips[tips["day"] == j]["tip"].values for j in jours_ordre]
bp = ax.boxplot(data_box, labels=["Jeu", "Ven", "Sam", "Dim"],
                patch_artist=True, medianprops=dict(color="red", linewidth=
couleurs_box = ["#BBDEFB", "#C8E6C9", "#FFE0B2", "#F8BBD0"]
for patch, c in zip(bp["boxes"], couleurs_box):
    patch.set_facecolor(c)
ax.set_ylabel("Pourboire ($)")
```

```
ax.set_title("Pourboire par jour")

# 4. Barplot groupe : tip moyen par jour + time
ax = axes[1, 1]
pivot = tips.groupby(["day", "time"])["tip"].mean().unstack(fill_value=0)
pivot = pivot.reindex(jours_ordre)
x = np.arange(len(jours_ordre))
w = 0.35

b1 = ax.bar(x - w / 2, pivot.get("Lunch", [0] * 4), w,
            label="Dejeuner", color="#42A5F5")
b2 = ax.bar(x + w / 2, pivot.get("Dinner", [0] * 4), w,
            label="Diner", color="#EF5350")
for bars in [b1, b2]:
    for bar in bars:
        h = bar.get_height()
        if h > 0:
            ax.text(bar.get_x() + bar.get_width() / 2, h + 0.05,
                    f"{h:.2f}", ha="center", fontsize=8)
ax.set_xticks(x)
ax.set_xticklabels(["Jeu", "Ven", "Sam", "Dim"])
ax.set_ylabel("Pourboire moyen ($)")
ax.set_title("Pourboire moyen par jour et moment")
ax.legend(fontsize=9)

plt.tight_layout()
plt.savefig("dashboard_tips.png", dpi=200, bbox_inches="tight")
plt.show()
print("\nDashboard exporte : dashboard_tips.png")

# ------------------------------------------------------------
# Etape 5 : Conclusions
# ------------------------------------------------------------

# 1. Le dimanche genere les pourboires moyens les plus eleves (~3.26 $),
#    probablement lie a des repas en famille plus consequents.
#
# 2. Les hommes laissent un pourboire moyen legerement superieur en valeur
#    absolue, mais les femmes sont souvent plus genereuses en pourcentage.
#
# 3. Il n'y a pas de difference notable entre fumeurs et non-fumeurs
#    en termes de pourboire moyen.
#
# 4. La correlation entre l'addition et le pourboire est forte (~0.68),
#    confirmant que les pourboires augmentent avec le montant de l'additior
#
# 5. Le diner genere des pourboires plus eleves que le dejeuner,
#    ce qui s'explique par des additions generalement plus importantes le s
```