R Niveau I

R Niveau I — Plan de cours détaillé

Formation : Initiation au langage R **Durée** : 2 jours (14 heures) **Horaires** : 9h00 – 17h00

JOUR 1 — Découverte de R

Module 1 : Introduction à R et RStudio (9h00 – 10h30)

Objectifs : Installer R et RStudio, comprendre l'interface, exécuter ses premières commandes.

Contenu détaillé :

1. **Pourquoi R ?** (15 min)
    - R dans l'écosystème data science (comparaison Python, SAS, Excel)
    - Open source, communauté active, reproductibilité
    - Cas d'usage : statistique, bioinformatique, finance, sciences sociales
2. **Installation de R et RStudio** (15 min)
    - Téléchargement depuis CRAN et posit.co
    - Démonstration de l'installation pas à pas
    - Vérification de l'installation
3. **L'interface RStudio** (20 min)
    - Les 4 panneaux : Console, Source, Environment/History, Files/Plots/Help
    - Personnalisation : thème, disposition, raccourcis clavier
    - Créer un nouveau script R

4. **La console R** (20 min)
    - R comme calculatrice : opérations arithmétiques
    - Affectation avec `<-` et `=`
    - Afficher et inspecter des valeurs
    - L'historique des commandes
5. **Les scripts R** (10 min)
    - Créer, sauvegarder, exécuter un script (.R)
    - Commentaires avec `#`
    - Exécuter ligne par ligne vs bloc
6. **Obtenir de l'aide** (10 min)
    - `?fonction`, `help(fonction)`, `??mot_clé`
    - Onglet Help de RStudio
    - Exemples avec `example(mean)`

Activité : Créer un script qui effectue 10 calculs variés et les affecte à des variables nommées.

Module 2 : Les objets R (10h45 – 12h15)

Objectifs : Identifier et créer les objets fondamentaux de R, comprendre les types de données.

Contenu détaillé :

1. **Les types atomiques** (15 min)
    - `numeric` (double), `integer` (suffixe L), `character`, `logical`
    - `complex` (mention rapide)
    - Vérifier un type : `class()`, `typeof()`, `is.numeric()`, `is.character()`
2. **Les vecteurs** (20 min)
    - Création : `c()`, `seq()`, `rep()`, opérateur `:`
    - Vecteurs nommés : `names()`

    - Propriété fondamentale : un seul type par vecteur (coercition automatique)
    - Opérations vectorisées : addition, multiplication, recyclage

3. **L'indexation de vecteurs** (15 min)
    - Par position : `v[1]`, `v[c(1,3)]`
    - Par exclusion : `v[-2]`
    - Par condition logique : `v[v > 5]`
    - Par nom : `v["nom"]`

4. **Les matrices** (10 min)
    - `matrix()` : `nrow`, `ncol`, `byrow`
    - Dimensions : `dim()`, `nrow()`, `ncol()`
    - Indexation : `m[i, j]`, `m[i, ]`, `m[, j]`

5. **Les listes** (15 min)
    - `list()` : conteneur hétérogène
    - Accès : `$nom`, `[[ ]]` (élément), `[ ]` (sous-liste)
    - Listes nommées
    - Quand utiliser une liste vs un vecteur

6. **Les data.frames** (10 min)
    - `data.frame()` : le tableau de données
    - Accès colonnes : `df$col`, `df[, "col"]`, `df[, c("a","b")]`
    - Accès lignes : `df[1:5, ]`
    - `str()`, `head()`, `summary()`

7. **Les facteurs** (5 min)
    - `factor()` : variables catégorielles
    - `levels()`, facteurs ordonnés
    - Utilité pour les modèles statistiques et les graphiques

8. **Conversions de types** (5 min)
    - `as.numeric()`, `as.character()`, `as.logical()`, `as.integer()`
    - `as.data.frame()`, `as.matrix()`

- Pièges courants de la coercition

Activité : Créer un data.frame de 5 étudiants (nom, âge, note, réussite) et le manipuler.

Module 3 : Les fonctions de base (13h30 – 15h00)

Objectifs : Utiliser les fonctions intégrées de R et écrire ses premières fonctions personnalisées.

Contenu détaillé :

1. **Fonctions mathématiques** (15 min)
   - `sqrt()`, `abs()`, `round()`, `ceiling()`, `floor()`
   - `log()`, `log10()`, `exp()`
   - `max()`, `min()`, `range()`, `sum()`, `prod()`, `cumsum()`
2. **Fonctions statistiques** (20 min)
   - `mean()`, `median()`, `sd()`, `var()`
   - `quantile()`, `IQR()`
   - `summary()` : résumé en une ligne
   - `cor()` : corrélation entre deux vecteurs
   - `table()` : tableau de fréquences
3. **Manipulation de chaînes** (15 min)
   - `paste()` et `paste0()` : concaténation
   - `nchar()` : longueur
   - `substr()`, `substring()` : extraction
   - `toupper()`, `tolower()` : casse
   - `gsub()`, `sub()` : remplacement
   - `grep()`, `grepl()` : recherche de motifs
4. **Fonctions logiques** (10 min)
   - `any()`, `all()` : au moins un / tous vrais
   - `which()` : indices des vrais
   - `ifelse()` : condition vectorisée

    - Opérateurs `&`, `|`, `!`, `&&`, `||`

5. **Créer ses propres fonctions** (25 min)
    - Syntaxe : `function(arg1, arg2 = default) { ... }`
    - `return()` explicite vs implicite
    - Arguments par défaut
    - Portée des variables (scope)
    - Exemple : fonction qui calcule un z-score
6. **Appliquer une fonction** (5 min)
    - `sapply()`, `lapply()` : aperçu rapide
    - Appliquer une fonction custom à un vecteur

Activité : Écrire 3 fonctions — calcul d'IMC, standardisation z-score, nettoyage de texte.

Module 4 : Atelier pratique Jour 1 (15h15 – 17h00)

Objectifs : Consolider les acquis des Modules 1 à 3 par la pratique guidée.

Contenu :

1. **Exercice guidé 1** (20 min) — Vecteurs et indexation
    - Créer des vecteurs de températures, les filtrer, calculer des statistiques
2. **Exercice guidé 2** (20 min) — Data.frames
    - Construire un data.frame de ventes, ajouter des colonnes calculées
3. **Exercice guidé 3** (20 min) — Fonctions
    - Écrire une fonction de conversion Celsius/Fahrenheit
    - L'appliquer à un vecteur de mesures
4. **Exercice guidé 4** (25 min) — Mini-analyse
    - Créer un jeu de données complet, calculer des statistiques par groupe
5. **Correction collective et questions** (20 min)

JOUR 2 — Manipulation de données

Module 5 : Importer et exporter des données (9h00 – 10h30)

Objectifs : Charger des données depuis des sources variées et les explorer.

Contenu détaillé :

1. **read.csv() et read.table()** (20 min)
    - Paramètres essentiels : `sep`, `header`, `dec`, `stringsAsFactors`
    - `na.strings` : gérer les valeurs manquantes à l'import
    - `encoding` : UTF-8, Latin1
    - `read.csv2()` pour les fichiers français (`;` et `,`)
2. **read.xlsx avec le package readxl** (10 min)
    - `install.packages("readxl")` et `library(readxl)`
    - `read_excel()` : paramètres `sheet`, `range`, `col_names`
3. **readRDS et saveRDS** (10 min)
    - Format natif R : compact, rapide, préserve les types
    - `saveRDS(objet, "fichier.rds")` / `readRDS("fichier.rds")`
4. **write.csv et write.table** (10 min)
    - `row.names = FALSE`
    - `write.csv2()` pour le format français
5. **Exploration initiale** (25 min)
    - `str()` : structure complète
    - `head()`, `tail()` : premières / dernières lignes
    - `summary()` : résumé statistique
    - `dim()`, `nrow()`, `ncol()` : dimensions
    - `names()`, `colnames()` : noms de colonnes
    - `class()` : type de chaque colonne

6. **Gestion des valeurs manquantes** (15 min)
    - `is.na()`, `sum(is.na(df))`
    - `complete.cases()`
    - `na.rm = TRUE` dans les fonctions
    - `na.omit()` : supprimer les lignes incomplètes

Activité : Importer un CSV avec des problèmes (encodage, séparateur, NA), le nettoyer et l'explorer.

Module 6 : Manipulation de data.frames (10h45 – 12h15)

Objectifs : Maîtriser les opérations courantes de manipulation tabulaire en base R.

Contenu détaillé :

1. **Sélection de colonnes** (10 min)
    - `df$col`, `df[, "col"]`, `df[, c("a", "b")]`
    - Sélection par indice numérique
2. **Filtrage de lignes** (15 min)
    - Conditions logiques : `df[df$age > 30, ]`
    - `subset(df, age > 30, select = c(nom, age))`
    - Combinaison de conditions : `&`, `|`
3. **Tri** (10 min)
    - `order()` : retourne les indices triés
    - `df[order(df$note), ]` : tri croissant
    - `df[order(-df$note), ]` : tri décroissant
    - Tri multi-critères
4. **Ajout de colonnes calculées** (10 min)
    - `df$nouvelle <- df$a + df$b`
    - `transform(df, ratio = a / b)`
    - `within(df, { ... })`
5. **Merge et jointures** (20 min)
    - `merge(x, y, by = "clé")` : jointure naturelle

- `all.x = TRUE` : left join
- `all.y = TRUE` : right join
- `all = TRUE` : full join
- Jointure sur plusieurs colonnes : `by = c("a", "b")`

6. **Reshape** (10 min)
   - `stack()` et `unstack()` : format long ↔ large
   - `reshape()` : transformation plus contrôlée
7. **Agrégation** (15 min)
   - `aggregate(valeur ~ groupe, data = df, FUN = mean)`
   - `tapply(df$valeur, df$groupe, summary)`
   - Agrégation multi-fonctions

Activité : Pipeline complet — filtrer, trier, joindre deux tables, agréger par groupe.

Module 7 : Introduction à la visualisation (13h30 – 15h00)

Objectifs : Créer des graphiques informatifs avec le système graphique de base de R.

Contenu détaillé :

1. **plot() — Nuage de points** (15 min)
   - `plot(x, y)` : scatterplot de base
   - Paramètres : `main`, `xlab`, `ylab`, `col`, `pch`, `cex`
   - Types : `type = "p"`, `"l"`, `"b"`, `"h"`
2. **hist() — Histogramme** (10 min)
   - `breaks` : nombre de classes
   - `col`, `border`
   - Ajouter une courbe de densité
3. **boxplot() — Boîte à moustaches** (10 min)
   - `boxplot(valeur ~ groupe)` : comparaison par groupe
   - Interprétation : médiane, quartiles, outliers
   - `horizontal = TRUE`

4. **barplot() — Diagramme en barres** (10 min)
    - `barplot(table(df$var))`
    - Barres empilées et côte à côte
    - `legend.text`, `args.legend`
5. **Paramètres graphiques avancés** (15 min)
    - `par()` : marges, couleurs, polices
    - `pch` (1-25), `lty` (1-6), `col` (noms, hex, rgb)
    - `cex` (taille), `lwd` (épaisseur)
6. **Combiner des graphiques** (10 min)
    - `par(mfrow = c(2, 2))` : grille 2×2
    - `layout()` : disposition personnalisée
7. **Ajouter des éléments** (10 min)
    - `legend()`, `abline()`, `text()`, `points()`, `lines()`
    - `title()` pour ajouter des titres
8. **Exporter des graphiques** (10 min)
    - `pdf("fichier.pdf")` ... `dev.off()`
    - `png("fichier.png", width, height, res)`
    - Depuis RStudio : Export button

Activité : Créer un dashboard de 4 graphiques sur le jeu de données `iris`.

Module 8 : Projet intégrateur (15h15 – 17h00)

Objectifs : Mobiliser l'ensemble des compétences acquises sur un cas concret.

Contenu :

1. **Présentation du projet** (10 min)
    - Jeu de données : `airquality` (données de qualité de l'air à New York)
    - Objectif : analyser la relation entre température, ozone et vent
2. **Étape 1 : Import et exploration** (20 min)

    - Charger les données, examiner la structure
    - Identifier les valeurs manquantes
    - Statistiques descriptives globales
3. **Étape 2 : Nettoyage** (15 min)
    - Traitement des NA
    - Création de variables dérivées (mois en texte, catégories de température)
4. **Étape 3 : Statistiques descriptives** (15 min)
    - Moyennes par mois, corrélations
    - Tableaux de synthèse avec `aggregate()`
5. **Étape 4 : Visualisations** (20 min)
    - 4 graphiques commentés (scatter, hist, boxplot, barplot)
    - Dashboard multi-graphiques
6. **Étape 5 : Synthèse et interprétation** (10 min)
    - Rédiger 5 conclusions en commentaires R
7. **Correction collective et bilan** (15 min)
    - Tour de table, questions, ressources pour aller plus loin