MODULE 5 — QUALITÉ DES DONNÉES

Contrôler avant de calculer

1 / 10

POURQUOI CE MODULE ?

- Un indicateur faux peut conduire à une mauvaise décision
- Les erreurs de clé sont souvent invisibles
- La qualité doit être mesurée, pas supposée
- Chaque extraction doit embarquer des contrôles

2 / 10

PROFIL QUALITÉ RAPIDE

```
profil_qc <- df |>
  summarise(across(
    everything(),
    list(
      na_n = ~ sum(is.na(.x)),
      na_pct = ~ round(mean(is.na(.x)) * 100, 2),
      n_distinct = ~ n_distinct(.x)
    )
  ))
```

3 / 10

UNICITÉ DES CLÉS

```
test_unicite <- df |>
  summarise(
    nb_lignes = n(),
    nb_cles = n_distinct(id_commande)
  ) |>
  mutate(ok = nb_lignes == nb_cles)

test_unicite
```

4 / 10

CONTRÔLES MÉTIER

- Montants négatifs interdits (hors avoirs)
- Dates futures non autorisées
- Codes segment hors référentiel
- Volumes anormaux par région

5 / 10

RÉCONCILIATION BASE VS EXCEL

```
reco <- ca_base |>
  full_join(ca_excel, by = c("mois", "region")) |>
  mutate(
    ca_base = coalesce(ca_base, 0),
    ca_excel = coalesce(ca_excel, 0),
    ecart = ca_base - ca_excel,
    ecart_pct = if_else(ca_excel == 0, NA_real_,
ecart / ca_excel)
  )
```

6 / 10

SORTIE QUALITÉ ATTENDUE

- Statut global : OK / ALERTE
- Liste des anomalies bloquantes
- Écarts chiffrés par source
- Décision : poursuivre ou corriger

7 / 10

PATTERN RECOMMANDÉ

- Extraction
- Contrôles structurels
- Contrôles métier
- Réconciliation
- Validation d'analyse

8 / 10

ATELIER DU MODULE

- Créer une check-list automatique de contrôles
- Isoler les anomalies critiques
- Produire un tableau de réconciliation
- Décider si la donnée est exploitable

9 / 10

RÉCAPITULATIF

- ✓ La qualité est un prérequis à toute analyse
- ✓ Contrôles structurels + métier indispensables
- ✓ Réconciliation multi-sources chiffrée
- ✓ Sortie qualité formalisée pour décision

10 / 10

Speaker notes