PROJET INTÉGRATEUR

Votre première analyse de données complète

ANALYSE COMPLÈTE

entrée ▶ traitement ▶ sortie

PRÉSENTATION DU PROJET

Analyser les pourboires d'un restaurant

- Dataset : tips (244 repas dans un restaurant)
- Colonnes : total_bill, tip, sex, smoker, day, time, size
- Question : quels facteurs influencent le pourboire ?
- Pipeline : import → explorer → nettoyer → stats → visualiser

DATASET TIPS

	col_A	col_B	col_C
0	…	…	…
1	…	…	…
2	…	…	…

ÉTAPE 1 : IMPORT DES DONNÉES

Charger les bibliothèques et le dataset

```python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# Charger le dataset tips (intégré à seaborn)
df = sns.load_dataset('tips')

# Vérifier le chargement
print(f'Dimensions : {df.shape}')  # (244, 7)
print(f'Colonnes : {list(df.columns)}')
print(df.head())
```

CHARGER LES DONNÉES

📄 fichier ↔ 🐍 Python

ÉTAPE 2 : EXPLORATION

Comprendre la structure des données

```python
# Types et valeurs manquantes
print(df.info())
print(f'\nValeurs manquantes :\n{df.isnull().sum()}')

# Statistiques descriptives
print(df.describe())

# Colonnes catégorielles
print(f'\nJours : {df["day"].unique()}')
print(f'Moments : {df["time"].unique()}')
print(f'Tailles : {sorted(df["size"].unique())}')

# Pourboire moyen
```

EXPLORER LA STRUCTURE

	col_A	col_B	col_C
0	…	…	…
1	…	…	…
2	…	…	…

ÉTAPE 3 : NETTOYAGE

Préparer les données pour l'analyse

```
# Créer la colonne pourcentage de pourboire
df['tip_pct'] = (df['tip'] / df['total_bill'] * 100).round

# Détecter les valeurs aberrantes
print('Pourboires extrêmes :')
print(df[df['tip_pct'] > 40][['total_bill', 'tip', 'tip_pc

# Recoder en français pour les graphiques
jours_fr = {'Sun': 'Dim', 'Sat': 'Sam',
            'Thur': 'Jeu', 'Fri': 'Ven'}
df['jour'] = df['day'].map(jours_fr)

moment_fr = {'Lunch': 'Déjeuner', 'Dinner': 'Dîner'}
```

NETTOYER LES DONNÉES

Nettoyer les données ✨ → propre

ÉTAPE 4 : STATISTIQUES

Répondre aux questions avec les chiffres

```
# Pourboire moyen par jour
par_jour = df.groupby('jour')['tip_pct'].agg(
    ['mean', 'median', 'count']
).round(1)
print('Par jour :\n', par_jour)

# Déjeuner vs Dîner
par_moment = df.groupby('moment')['tip_pct'].mean().round
print(f'\nDéjeuner : {par_moment["Déjeuner"]}%')
print(f'Dîner : {par_moment["Dîner"]}%')

# Fumeurs vs non-fumeurs
par_fumeur = df.groupby('smoker')['tip_pct'].mean().round
```

STATISTIQUES PAR GROUPE

Statistiques par groupe

ÉTAPE 5 : VISUALISATION

Transformer les chiffres en histoire visuelle

```
fig, axes = plt.subplots(2, 2, figsize=(14, 10))

# 1. Scatter : addition vs pourboire
axes[0, 0].scatter(df['total_bill'], df['tip'],
                   alpha=0.6, c='#00f3ff', s=40)
axes[0, 0].set_title('Addition vs Pourboire')
axes[0, 0].set_xlabel('Addition ($)')
axes[0, 0].set_ylabel('Pourboire ($)')

# 2. Boxplot par jour
jours_ordre = ['Jeu', 'Ven', 'Sam', 'Dim']
data_box = [df[df['jour'] == j]['tip_pct'] for j in jours_ord
axes[0, 1].boxplot(data_box, labels=jours_ordre, patch_artist
```

DASHBOARD 4 GRAPHIQUES

ÉTAPE 6 : SYNTHÈSE

Conclusions de l'analyse

- Corrélation positive entre addition et pourboire ($r \approx 0.67$)
- Pourboire moyen : environ 16 % de l'addition
- Déjeuner légèrement plus généreux en pourcentage
- Week-end : groupes plus grands, additions plus élevées
- Pas de différence significative fumeurs vs non-fumeurs

5 CONCLUSIONS

`"5 conclusions_1"` → valeur

`"5 conclusions_2"` → valeur

`"5 conclusions_3"` → valeur

RÉCAPITULATIF

Votre pipeline d'analyse complet

- ✓ Import : pandas, numpy, matplotlib, seaborn
- ✓ Explorer : head, info, describe, unique
- ✓ Nettoyer : colonnes calculées, recodage, valeurs aberrantes
- ✓ Statistiques : groupby, agg, corrélation
- ✓ Visualiser : scatter, boxplot, hist, bar
- ✓ Synthétiser : transformer les chiffres en décisions