MANIPULATION DE DATA.FRAMES

Transformer vos données

BRUT → EXPLOITABLE

Brut

→

Exploitable

1 / 8

SÉLECTION DE COLONNES

Choisir les variables utiles

```
data(mtcars)

# Une colonne (vecteur)
mtcars$mpg

# Une colonne (data.frame)
mtcars[, "mpg"]

# Plusieurs colonnes
mtcars[, c("mpg", "cyl", "hp")]

# Par position
mtcars[, 1:3]
```

SÉLECTIONNER

[1]

[2]

[3]

[4]

2 / 8

FILTRAGE DE LIGNES

Garder ce qui compte

```
# Condition simple
mtcars[mtcars$cyl == 6, ]

# Conditions combinées
mtcars[mtcars$cyl > 4 & mtcars$hp > 100, ]

# Avec subset (plus lisible)
subset(mtcars, cyl > 4 & hp > 100,
       select = c(mpg, cyl, hp))
```

FILTRER
données ▸ Filtrer ▸ résultat

3 / 8

TRI

Ordonner vos données

```
# Tri croissant par mpg
mtcars[order(mtcars$mpg), ]

# Tri décroissant
mtcars[order(-mtcars$mpg), ]

# Tri multi-critères
mtcars[order(mtcars$cyl, -mtcars$mpg), ]
```

4 / 8

COLONNES CALCULÉES

Enrichir vos données

```
df <- mtcars[1:5, c("mpg", "wt", "hp")]

# Nouvelle colonne
df$ratio <- df$hp / df$wt

# Avec transform
df <- transform(df,
  efficacite = mpg / hp,
  categorie  = ifelse(mpg > 20, "eco",
"sport")
)
head(df)
```

5 / 8

MERGE ET JOINTURES

Fusionner deux tables

```
produits <- data.frame(
  id = 1:3,
  nom = c("Pomme", "Pain", "Lait")
)
prix <- data.frame(
  id = c(1, 2, 4),
  prix = c(1.5, 2.0, 3.0)
)

# Inner join (défaut)
merge(produits, prix, by = "id")

# Left join
merge(produits, prix, by = "id", all.x =
TRUE)

# Full join
merge(produits, prix, by = "id", all = TRUE)
```

FUSIONNER

6 / 8

AGRÉGATION

Résumer par groupe

```
# Moyenne de mpg par cylindres
aggregate(mpg ~ cyl, data = mtcars, FUN =
mean)
#   cyl      mpg
# 1   4 26.66364
# 2   6 19.74286
# 3   8 15.10000

# Plusieurs stats
aggregate(cbind(mpg, hp) ~ cyl,
  data = mtcars, FUN = mean)

# Avec tapply
tapply(mtcars$mpg, mtcars$cyl, mean)
```

GROUPER

données ▸ Grouper ▸ résultat

7 / 8

RÉCAPITULATIF

Data.frames sculptés

- ✓ Sélection : df$col, df[, c(...)]
- ✓ Filtrage : df[condition,] ou subset()
- ✓ Tri : df[order(...),]
- ✓ Colonnes : df$new ← calcul
- ✓ Jointures : merge(x, y, by)
- ✓ Agrégation : aggregate(y ~ x, FUN)

8 / 8

Speaker notes