PROJET INTÉGRATEUR

Tout assembler sur des données réelles

PROJET COMPLET

ÉTAPE 1 : EXPLORATION

Comprendre le jeu de données

```r
data(airquality)

str(airquality)
# 153 obs. of 6 variables

dim(airquality)    # 153 x 6
head(airquality)
summary(airquality)

# Comptage des NA
sapply(airquality, function(x) sum(is.na(x)))
# Ozone: 37, Solar.R: 7, autres: 0
```

EXPLORER

f(x) → y

ÉTAPE 2 : NETTOYAGE

Préparer les données

```r
# Retirer les NA d'ozone
aq <- airquality[!is.na(airquality$Ozone), ]
nrow(aq)  # 116 lignes restantes

# Mois en texte
mois_noms <- c("Mai","Juin","Juil","Août","Sept")
aq$Mois_txt <- mois_noms[aq$Month - 4]

# Catégorie température
aq$Cat_temp <- ifelse(aq$Temp > 80, "Chaud", "Tempéré")

head(aq)
```

NETTOYER

brut ✨ → propre

ÉTAPE 3 : STATISTIQUES

Résumer par groupe

```r
# Moyenne d'ozone par mois
aggregate(Ozone ~ Mois_txt, data = aq, FUN = mean)

# Corrélation température / ozone
cor(aq$Temp, aq$Ozone)  # ~0.70

# Résumé par catégorie
aggregate(Ozone ~ Cat_temp, data = aq,
  FUN = function(x) c(moy = mean(x), et = sd(x)))
```

STATISTIQUES

① ② ③

ÉTAPE 4 : VISUALISATIONS

Quatre graphiques clés

```r
par(mfrow = c(2, 2))

# 1. Scatter
plot(aq$Temp, aq$Ozone, pch = 19, col = "#00f3ff",
  main = "Temp vs Ozone", xlab = "Temp (F)", ylab = "Ozone (
abline(lm(Ozone ~ Temp, data = aq), col = "red", lwd = 2)

# 2. Histogramme
hist(aq$Ozone, breaks = 15, col = "#a78bfa",
  main = "Distribution Ozone", xlab = "Ozone")

# 3. Boxplot par mois
boxplot(Ozone ~ Month, data = aq, col = "#10b981",
```

DASHBOARD

① ② ③

ÉTAPE 5 : SYNTHÈSE

Interpréter et conclure

- Ozone fortement corrélé à la température (r ≈ 0.70)
- Pic d'ozone en juillet-août
- Le vent réduit les niveaux d'ozone
- Valeurs extrêmes présentes en été
- 24% de NA sur l'ozone — biais potentiel

✓ Conclusions

BILAN DE LA FORMATION

R Niveau I accompli

- ✓ Jour 1 : R, RStudio, objets, fonctions
- ✓ Jour 2 : import, manipulation, visualisation
- ✓ Projet intégrateur réalisé
- ✓ Prochaine étape : R Niveau II (Tidyverse + Stats)