R Niveau II — Plan de cours détaillé

Formation : R avancé orienté bases de données et exploitation Excel **Durée** : 2 jours (14 heures) **Horaires** : 9h00 – 17h00 **Prérequis** : R Niveau I ou équivalent

Adaptation pédagogique : le fil rouge peut être appliqué à un jeu de données proche du contexte professionnel des apprenants pour couvrir les notions abordées (BDD, extraction tableur, requêtes avancées et statistique descriptive pratique).

JOUR 1 — Connexion données, extraction et requêtes avancées

Module 1 : Accéder aux bases de données avec R (9h00 – 10h30)

Objectifs : Se connecter à une base, comprendre la logique table distante, exécuter des requêtes efficaces avec `dplyr` / `dbplyr`.

Contenu détaillé :

1. **Architecture de données en entreprise** (10 min)
    - Différence fichiers plats, tableur et base relationnelle
    - Pourquoi éviter de tout charger en mémoire locale
    - Logique ETL/ELT dans un flux analytique
2. **Connexion DBI** (20 min)
    - `DBI::dbConnect()` avec SQLite, PostgreSQL, MySQL, SQL Server
    - Gestion des credentials via variables d'environnement
    - `dbListTables()`, `dbListFields()`, `dbGetQuery()`
3. **Tables distantes avec dbplyr** (20 min)
    - `tbl(con, "nom_table")` et lazy evaluation

    - Utiliser `select`, `filter`, `mutate`, `summarise` sans ramener la table
    - `show_query()` pour visualiser le SQL généré
4. **Performance et bonnes pratiques** (15 min)
    - Filtrer tôt, sélectionner peu de colonnes
    - Limiter les `collect()` aux jeux finalisés
    - Tracer les requêtes coûteuses
5. **Atelier guidé** (25 min)
    - Connexion à une base de ventes
    - Agrégation CA par mois et canal
    - Contrôle des résultats SQL vs R local

Activité : Requête de pilotage mensuel 100% poussée côté base.

Module 2 : Extraction de fichiers Excel / tableur (10h45 – 12h15)

Objectifs : Importer et fiabiliser des fichiers Excel hétérogènes pour les rendre exploitables dans un pipeline R.

Contenu détaillé :

1. **Lecture structurée d'Excel** (20 min)
    - `readxl::excel_sheets()`, `read_excel()`
    - Choisir `sheet`, `range`, `skip`, `col_types`
    - Gestion des formats date, devise, pourcentage
2. **Nettoyage de structure tableur** (20 min)
    - `janitor::clean_names()` et standardisation des colonnes
    - Suppression des lignes vides, notes, totaux parasites
    - Normalisation des codes et libellés métier
3. **Reshape et normalisation** (20 min)
    - `pivot_longer()` pour déplier les colonnes périodiques
    - `separate()`, `unite()`, `fill()` pour structurer
    - Passage vers un format "tidy" prêt pour jointure

4. **Industrialisation multi-fichiers** (15 min)
    - `list.files()` + `purrr::map_dfr()`
    - Traçabilité de la source (`.id`)
    - Gestion d'erreur avec `possibly()`
5. **Atelier guidé** (15 min)
    - Consolider 12 exports mensuels Excel
    - Obtenir une table unique propre et documentée

Activité : Transformer un classeur "messy" en table analytique fiable.

Module 3 : Requêtes avancées I (13h30 – 15h00)

Objectifs : Construire des requêtes robustes pour analyser des données relationnelles complexes.

Contenu détaillé :

1. **Jointures métier** (20 min)
    - `left_join`, `inner_join`, `full_join`, `anti_join`, `semi_join`
    - Jointures multi-clés et gestion des collisions de colonnes
    - Contrôle du cardinal (1-1, 1-n, n-n)
2. **Sous-ensembles et conditions avancées** (20 min)
    - Filtres conditionnels multi-règles avec `case_when()`
    - Segmentation métier (clients actifs/inactifs, panier élevé/faible)
    - Équivalent SQL des sous-requêtes avec pipelines dplyr
3. **Déduplication et intégrité** (15 min)
    - `distinct()` vs clé métier composite
    - Détection de doublons contradictoires
    - Règles de priorité pour garder la bonne ligne
4. **Atelier guidé** (35 min)
    - Fusion ventes + catalogue + clients + objectifs
    - Production d'une table d'analyse unique
    - Validation de cohérence avant restitution

Activité : Construire un dataset unifié prêt à être diffusé à l'équipe métier.

Module 4 : Requêtes avancées II et automatisation (15h15 – 17h00)

Objectifs : Gérer les calculs analytiques avancés et fiabiliser les extractions récurrentes.

Contenu détaillé :

1. **Fonctions de fenêtre** (20 min)
    - `row_number()`, `min_rank()`, `dense_rank()`
    - `lag()`, `lead()` pour évolutions temporelles
    - Cumulés et parts relatives par groupe
2. **Pipelines paramétrables** (20 min)
    - Fonctions personnalisées pour requêtes répétables
    - Paramètres date, région, canal, produit
    - Pattern "une fonction = un livrable"
3. **Robustesse opérationnelle** (20 min)
    - `tryCatch()`, `safely()`, journalisation de traitement
    - Contrôles bloquants/non bloquants
    - Export CSV/Excel automatisé avec nomenclature stable
4. **Atelier guidé** (25 min)
    - Créer une extraction quotidienne "top clients"
    - Ajouter alertes qualité et fichier de log

Activité : Construire un script réutilisable en contexte production.

JOUR 2 — Qualité des données et statistiques descriptives pratiques

---

Module 5 : Qualité des données et consolidation (9h00 – 10h30)

Objectifs : Contrôler la fiabilité des données avant calcul d'indicateurs.

Contenu détaillé :

1. **Contrôles structurels** (20 min)
    - Taux de valeurs manquantes par variable
    - Vérification types et domaines autorisés
    - Conformité des clés et unicité
2. **Contrôles métier** (25 min)
    - Montants négatifs anormaux, dates incohérentes
    - Écarts entre export Excel et base transactionnelle
    - Seuils d'alerte et indicateurs de confiance
3. **Réconciliation multi-sources** (20 min)
    - Comparer deux sources via clés communes
    - Identifier lignes absentes de l'une ou l'autre
    - Produire une table de différentiel
4. **Atelier guidé** (25 min)
    - Pack de tests qualité sur un dataset brut
    - Sortie : "OK pour analyse" ou "à corriger"

Activité : Déployer une check-list qualité réutilisable.

Module 6 : Statistiques descriptives pratiques (10h45 – 12h15)

Objectifs : Produire des indicateurs descriptifs robustes et interprétables pour les métiers.

Contenu détaillé :

1. **Indicateurs de tendance centrale** (15 min)
    - Moyenne, médiane, moyenne tronquée
    - Quand privilégier la médiane
    - Impact des valeurs extrêmes
2. **Dispersion et stabilité** (20 min)

    - Écart-type, IQR, coefficient de variation
    - Lecture opérationnelle de la variabilité
    - Comparaison entre segments
3. **Descriptif catégoriel** (15 min)
    - Fréquences, proportions, top N
    - Tableaux croisés utiles à la décision
    - Évolution des parts dans le temps
4. **Séries temporelles descriptives** (20 min)
    - Variations MoM, YoY, cumul annuel
    - Moyennes mobiles et lissage simple
    - Détection visuelle des ruptures
5. **Atelier guidé** (20 min)
    - Construire un tableau d'indicateurs lisible pour un comité métier

Activité : Résumer 100k lignes en 10 KPI exploitables.

Module 7 : Restitution et communication des résultats (13h30 – 15h00)

Objectifs : Transformer les sorties analytiques en livrables actionnables.

Contenu détaillé :

1. **Tableaux de synthèse** (20 min)
    - `gt` et `dplyr` pour produire des tableaux propres
    - Mise en évidence des écarts et alertes
    - Formatage des montants, taux, dates
2. **Visualisations descriptives utiles** (25 min)
    - Barres, lignes, boxplots, heatmaps simples
    - Éviter les graphiques décoratifs non décisionnels
    - Titres orientés message métier
3. **Exports et diffusion** (20 min)
    - `write_csv()`, `openxlsx::write.xlsx()`

    - Nommage standard, versionnement et archivage
    - Préparer un kit de livraison (données + script + note)
4. **Atelier guidé** (25 min)
    - Construire une page de synthèse hebdomadaire
    - Comparer deux périodes et commenter les écarts

Activité : Livraison d'un reporting descriptif prêt à partager.

Module 8 : Projet fil rouge de fin de formation (15h15 – 17h00)

Objectifs : Assembler l'ensemble du workflow dans un cas concret de bout en bout.

Contenu :

1. **Cadrage du besoin** (10 min)
    - Question métier, périmètre, sources disponibles
    - Définition des indicateurs de sortie
    - Choix possible d'un jeu de données proche du contexte professionnel des apprenants
2. **Extraction multi-sources** (20 min)
    - Données transactionnelles en base
    - Objectifs mensuels en Excel
    - Réconciliation et contrôle qualité
3. **Requêtes avancées** (20 min)
    - Jointures métier, ranking clients, KPI par segment
    - Construction d'une table analytique finale
4. **Analyse descriptive pratique** (20 min)
    - KPI centraux, dispersion, alertes opérationnelles
    - Lecture des tendances et recommandations
5. **Restitution finale** (20 min)
    - Tableau + graphique + synthèse rédigée
    - Présentation orale courte des conclusions

6. **Bilan et plan d'action** (15 min)
    - Checklist de réutilisation en contexte réel
    - Axes d'industrialisation après la formation