R Niveau II — Syllabus

Formation : R avancé orienté bases de données et exploitation Excel

Durée : 2 jours (14 heures) **Format** : Présentiel ou distanciel synchrone **Langue** : Français **Prérequis** : R Niveau I ou équivalent

Description

Cette formation R Niveau II est centrée sur un usage métier concret : exploiter les données d'entreprise issues de bases relationnelles et de fichiers tableur, automatiser les extractions, puis produire des analyses descriptives directement actionnables. Le parcours privilégie les pipelines reproductibles, les requêtes avancées et la qualité de données, avec une clôture sur la statistique descriptive appliquée aux cas réels des apprenants. Le contenu peut être adapté à un jeu de données proche du contexte professionnel des participants afin de couvrir les notions abordées sur des cas concrets.

Public cible

- Analystes manipulant des données stockées en SQL (PostgreSQL, MySQL, SQL Server, SQLite)
- Professionnels travaillant régulièrement avec des exports Excel/tableur
- Utilisateurs R souhaitant industrialiser leurs traitements de données
- Équipes BI / contrôle de gestion voulant fiabiliser leurs indicateurs dans R

Prérequis

- Avoir suivi R Niveau I ou maîtriser objets R, fonctions, import/export et data.frames
- Savoir écrire des filtres simples et agrégations de base avec dplyr
- R et RStudio installés (version R ≥ 4.3)
- Accès à une base de test (ou SQLite locale fournie pendant la formation)

Objectifs pédagogiques

À l'issue de cette formation, le stagiaire sera capable de :

1. **Se connecter à une base de données depuis R** avec DBI et gérer un flux sécurisé d'accès
2. **Travailler sur des tables distantes** via dbplyr en gardant les calculs côté SQL
3. **Importer des classeurs Excel complexes** (multi-feuilles, en-têtes hétérogènes, typage)
4. **Nettoyer et normaliser des données tableur** avec tidyr, stringr et janitor
5. **Écrire des requêtes avancées** : jointures multi-clés, anti-joins, fenêtres, sous-requêtes
6. **Automatiser l'extraction multi-sources** (base + fichiers) de manière robuste
7. **Contrôler la qualité des données** : doublons, valeurs manquantes, cohérence métier
8. **Produire des statistiques descriptives pratiques** pour la prise de décision opérationnelle
9. **Restituer les résultats** sous forme de tableaux et graphiques exploitables
10. **Structurer un mini-projet analytique** reproductible et documenté

Compétences acquises

Compétence	Niveau
Connexion et interrogation de bases SQL depuis R	Autonomie
Extraction/normalisation de fichiers Excel	Maîtrise
Requêtes avancées avec dplyr/dbplyr	Autonomie
Contrôle qualité des données	Autonomie
Statistiques descriptives orientées métier	Maîtrise
Reporting et livrables analytiques	Autonomie

Modalités d'évaluation

- **Exercices guidés** à la fin de chaque module (base + tableur)
- **Atelier fil rouge** avec jeu de données multi-sources (adaptable au contexte professionnel)
- **Projet final** : extraction, requêtes avancées, synthèse descriptive
- **QCM de validation** en fin de journée

Méthodes pédagogiques

- **Démonstrations live** en RStudio, avec connexion base et imports tableur réels
- **Ateliers progressifs** : du dataset brut vers des indicateurs fiables
- **Correction commentée** axée sur la robustesse et la lisibilité des scripts
- **Cas d'usage métier** proches des contextes apprenants (ventes, finance, opérations)
- **Bibliothèque de snippets** réutilisables en production

Ressources et outils

Outil / Package	Version	Usage
R	≥ 4.3	Langage
RStudio Desktop	≥ 2024.04	IDE
DBI + odbc / RSQLite	dernière	Connexion BDD
dbplyr	≥ 2.5	Requêtes SQL via dplyr
readxl + openxlsx	dernière	Lecture/écriture Excel
tidyverse	≥ 2.0	Manipulation et visualisation
janitor	≥ 2.2	Nettoyage et contrôle qualité
skimr	≥ 2.1	Résumé descriptif
gt / reactable	dernière	Tableaux de restitution
rmarkdown	≥ 2.25	Rapport reproductible

Installation :

```
install.packages(c(
  "tidyverse", "DBI", "dbplyr", "RSQLite", "odbc",
  "readxl", "openxlsx", "janitor", "skimr", "gt", "rmarkdown"
))
```

Programme détaillé

Jour 1 — Connexion données et extraction

Horaire	Module	Contenu
9h00 – 10h30	Module 1 : Bases de données avec R	DBI, connexions, tbl(), premiers filtres et agrégations côté SQL
10h30 – 10h45	*Pause*	

Horaire	Module	Contenu
10h45 – 12h15	Module 2 : Extraction Excel / tableur	readxl, multi-feuilles, typage, nettoyage, standardisation colonnes
12h15 – 13h30	*Déjeuner*	
13h30 – 15h00	Module 3 : Requêtes avancées I	Jointures complexes, sous-ensembles métier, anti-join, semi-join
15h00 – 15h15	*Pause*	
15h15 – 17h00	Module 4 : Requêtes avancées II	Fenêtres, ranking, calculs cumulés, industrialisation des extractions

Jour 2 — Exploitation et statistiques descriptives

Horaire	Module	Contenu
9h00 – 10h30	Module 5 : Qualité et consolidation des données	Contrôles, détection anomalies, réconciliation base/tableur
10h30 – 10h45	*Pause*	
10h45 – 12h15	Module 6 : Statistiques descriptives pratiques	Indicateurs robustes, dispersion, segmentation, séries temporelles
12h15 – 13h30	*Déjeuner*	
13h30 – 15h00	Module 7 : Restitution métier	Tableaux de bord descriptifs, visualisations utiles, exports
15h00 – 15h15	*Pause*	
15h15 – 17h00	Module 8 : Projet fil rouge	Cas complet Excel + BDD + requêtes avancées + synthèse descriptive

---

Ressources complémentaires recommandées

- *R for Data Science* (2e édition) — Wickham, Çetinkaya-Rundel, Grolemund
- *SQL for Data Analysis* — O'Reilly
- Documentation dbplyr — https://dbplyr.tidyverse.org/
- Documentation readxl — https://readxl.tidyverse.org/
- Tidyverse Cheatsheets — https://posit.co/resources/cheatsheets