# R Niveau II — Syllabus

## Formation : R avancé orienté bases de données et exploitation Excel

**Durée** : 2 jours (14 heures) **Format** : Présentiel ou distanciel synchrone **Langue** : Français **Prérequis** : R Niveau I ou équivalent

## Description

Cette formation R Niveau II est centrée sur un usage métier concret : exploiter les données d'entreprise issues de bases relationnelles et de fichiers tableur, automatiser les extractions, puis produire des analyses descriptives directement actionnables. Le parcours privilégie les pipelines reproductibles, les requêtes avancées et la qualité de données, avec une clôture sur la statistique descriptive appliquée aux cas réels des apprenants. Le contenu peut être adapté à un jeu de données proche du contexte professionnel des participants afin de couvrir les notions abordées sur des cas concrets.

## Public cible

- Analystes manipulant des données stockées en SQL (PostgreSQL, MySQL, SQL Server, SQLite)
- Professionnels travaillant régulièrement avec des exports Excel/tableur
- Utilisateurs R souhaitant industrialiser leurs traitements de données
- Équipes BI / contrôle de gestion voulant fiabiliser leurs indicateurs dans R

## Prérequis

- Avoir suivi R Niveau I ou maîtriser objets R, fonctions, import/export et data.frames
- Savoir écrire des filtres simples et agrégations de base avec dplyr
- R et RStudio installés (version R ≥ 4.3)
- Accès à une base de test (ou SQLite locale fournie pendant la formation)

---

## Objectifs pédagogiques

À l'issue de cette formation, le stagiaire sera capable de :

1. **Se connecter à une base de données depuis R** avec DBI et gérer un flux sécurisé d'accès
2. **Travailler sur des tables distantes** via dbplyr en gardant les calculs côté SQL
3. **Importer des classeurs Excel complexes** (multi-feuilles, en-têtes hétérogènes, typage)
4. **Nettoyer et normaliser des données tableur** avec tidyr, stringr et janitor
5. **Écrire des requêtes avancées** : jointures multi-clés, anti-joins, fenêtres, sous-requêtes
6. **Automatiser l'extraction multi-sources** (base + fichiers) de manière robuste
7. **Contrôler la qualité des données** : doublons, valeurs manquantes, cohérence métier
8. **Produire des statistiques descriptives pratiques** pour la prise de décision opérationnelle
9. **Restituer les résultats** sous forme de tableaux et graphiques exploitables
10. **Structurer un mini-projet analytique** reproductible et documenté

---

## Compétences acquises

| Compétence | Niveau |
| --- | --- |
| Connexion et interrogation de bases SQL depuis R | Autonomie |
| Extraction/normalisation de fichiers Excel | Maîtrise |
| Requêtes avancées avec dplyr/dbplyr | Autonomie |
| Contrôle qualité des données | Autonomie |
| Statistiques descriptives orientées métier | Maîtrise |
| Reporting et livrables analytiques | Autonomie |

---

## Modalités d'évaluation

- **Exercices guidés** à la fin de chaque module (base + tableur)
- **Atelier fil rouge** avec jeu de données multi-sources (adaptable au contexte professionnel)
- **Projet final** : extraction, requêtes avancées, synthèse descriptive
- **QCM de validation** en fin de journée

---

## Méthodes pédagogiques

- **Démonstrations live** en RStudio, avec connexion base et imports tableur réels
- **Ateliers progressifs** : du dataset brut vers des indicateurs fiables
- **Correction commentée** axée sur la robustesse et la lisibilité des scripts
- **Cas d'usage métier** proches des contextes apprenants (ventes, finance, opérations)
- **Bibliothèque de snippets** réutilisables en production

---

## Ressources et outils

| Outil / Package | Version | Usage |
|---|---|---|
| R | ≥ 4.3 | Langage |
| RStudio Desktop | ≥ 2024.04 | IDE |
| DBI + odbc / RSQLite | dernière | Connexion BDD |
| dbplyr | ≥ 2.5 | Requêtes SQL via dplyr |
| readxl + openxlsx | dernière | Lecture/écriture Excel |
| tidyverse | ≥ 2.0 | Manipulation et visualisation |
| janitor | ≥ 2.2 | Nettoyage et contrôle qualité |
| skimr | ≥ 2.1 | Résumé descriptif |
| gt / reactable | dernière | Tableaux de restitution |
| rmarkdown | ≥ 2.25 | Rapport reproductible |

**Installation** :

```
install.packages(c(
  "tidyverse", "DBI", "dbplyr", "RSQLite", "odbc",
  "readxl", "openxlsx", "janitor", "skimr", "gt", "rmarkdown"
))
```

---

## Programme détaillé

### Jour 1 — Connexion données et extraction

| Horaire | Module | Contenu |
|---|---|---|
| 9h00 – 10h30 | Module 1 : Bases de données avec R | DBI, connexions, tbl(), premiers filtres et agrégations côté SQL |
| 10h30 – 10h45 | *Pause* | |

| Horaire | Module | Contenu |
|---|---|---|
| 10h45 – 12h15 | Module 2 : Extraction Excel / tableur | readxl, multi-feuilles, typage, nettoyage, standardisation colonnes |
| 12h15 – 13h30 | *Déjeuner* | |
| 13h30 – 15h00 | Module 3 : Requêtes avancées I | Jointures complexes, sous-ensembles métier, anti-join, semi-join |
| 15h00 – 15h15 | *Pause* | |
| 15h15 – 17h00 | Module 4 : Requêtes avancées II | Fenêtres, ranking, calculs cumulés, industrialisation des extractions |

### Jour 2 — Exploitation et statistiques descriptives

| Horaire | Module | Contenu |
|---|---|---|
| 9h00 – 10h30 | Module 5 : Qualité et consolidation des données | Contrôles, détection anomalies, réconciliation base/tableur |
| 10h30 – 10h45 | *Pause* | |
| 10h45 – 12h15 | Module 6 : Statistiques descriptives pratiques | Indicateurs robustes, dispersion, segmentation, séries temporelles |
| 12h15 – 13h30 | *Déjeuner* | |
| 13h30 – 15h00 | Module 7 : Restitution métier | Tableaux de bord descriptifs, visualisations utiles, exports |
| 15h00 – 15h15 | *Pause* | |
| 15h15 – 17h00 | Module 8 : Projet fil rouge | Cas complet Excel + BDD + requêtes avancées + synthèse descriptive |

---

## Ressources complémentaires recommandées

- *R for Data Science* (2e édition) — Wickham, Çetinkaya-Rundel, Grolemund
- *SQL for Data Analysis* — O'Reilly
- Documentation dbplyr — https://dbplyr.tidyverse.org/
- Documentation readxl — https://readxl.tidyverse.org/
- Tidyverse Cheatsheets — https://posit.co/resources/cheatsheets