MODULE 2 — EXTRACTION EXCEL / TABLEUR

Importer, nettoyer et normaliser des fichiers réels

WORKFLOW

`readxl` → `nettoyage` → `table tidy`

PROBLÈMES FRÉQUENTS DES EXPORTS EXCEL

- Entêtes sur plusieurs lignes et cellules fusionnées
- Colonnes "montant" au format texte
- Feuilles multiples avec structures différentes
- Lignes de total ou commentaires à supprimer

LECTURE MAÎTRISÉE D'UN CLASSEUR

```r
library(readxl)

excel_sheets("objectifs.xlsx")

objectifs <- read_excel(
  "objectifs.xlsx",
  sheet = "Objectifs",
  skip = 2,
  col_types = c("text", "text", "numeric")
)
```

STANDARDISER LES COLONNES

```r
library(janitor)
library(dplyr)

objectifs_clean <- objectifs |>
  clean_names() |>
  rename(
    region = zone_vente,
    objectif_ca = ca_cible
  ) |>
  filter(!is.na(region), region != "")
```

PASSER DU LARGE AU LONG

```r
library(tidyr)

objectifs_tidy <- objectifs_wide |>
  pivot_longer(
    cols = jan_2025:dec_2025,
    names_to = "periode",
    values_to = "objectif_ca"
  ) |>
  separate(periode, c("mois", "annee"), sep = "_")
```

IMPORT MULTI-FICHIERS

```r
library(purrr)

imports <- list.files("exports", pattern = "\\.xlsx$", full.names = TRUE) |>
  set_names() |>
  map(~ read_excel(.x, sheet = "Data") |> clean_names()) |>
  list_rbind(names_to = "source_fichier")
```

GESTION D'ERREUR ROBUSTE

```r
safe_read_excel <- purrr::possibly(
  ~ read_excel(.x, sheet = "Data") |> clean_names(),
  otherwise = NULL
)

resultats <- fichiers |> map(safe_read_excel)
valides <- resultats |> compact()
```

CHECKLIST QUALITÉ AVANT JOINTURE

- Noms de colonnes homogènes
- Types compatibles avec la base SQL
- Clés métier sans NA critiques
- Volume attendu vs volume importé

ATELIER DU MODULE

- Importer 12 fichiers mensuels
- Uniformiser les structures
- Consolider en une table unique
- Préparer la table pour jointure SQL

RÉCAPITULATIF

- ✓ Extraction Excel contrôlée et reproductible
- ✓ Nettoyage structurel avec janitor + dplyr
- ✓ Normalisation tidy avec tidyr
- ✓ Imports robustes multi-fichiers