R Niveau II

R Niveau II — Jour 1 : Exercices pratiques

> Bases de données, extraction Excel et requêtes avancées

Jeu de données fil rouge

Les exercices reposent sur un contexte unique :

- `ventes_db` : table SQL des ventes (id_commande, date, client_id, produit_id, quantite, prix_net)
- `clients_db` : table SQL des clients (client_id, segment, region)
- `catalogue_xlsx` : fichier Excel (produit_id, famille, prix_public, statut)
- `objectifs_xlsx` : fichier Excel (mois, region, objectif_ca)

Module 1 : Connexion base de données avec R

Exercice 1.1 : Connexion SQLite et découverte [Difficulté: Facile]

Énoncé : Connectez-vous à une base SQLite nommée `business.db` et listez les tables disponibles.

1. Créer la connexion DBI
2. Lister les tables
3. Fermer la connexion

Solution

Exercice 1.2 : Première requête dbplyr [Difficulté: Intermédiaire]

Énoncé : À partir de la table `ventes` :

1. Créer un objet distant `tbl(con, "ventes")`
2. Filtrer les lignes avec `date >= "2025-01-01"`
3. Garder uniquement `date`, `region`, `prix_net`
4. Calculer le CA total par région
5. Afficher le SQL généré et collecter le résultat final

Solution

Exercice 1.3 : Limiter les volumes [Difficulté: Intermédiaire]

Énoncé : Pourquoi faut-il éviter `collect()` trop tôt ? Vérifiez sur cet exemple :

1. Version A : `collect()` puis `filter()`
2. Version B : `filter()` côté base puis `collect()`
3. Comparer le nombre de lignes ramenées

Solution

Module 2 : Import et nettoyage de fichiers Excel

Exercice 2.1 : Import multi-feuilles [Difficulté: Facile]

Énoncé : Le classeur `catalogue.xlsx` contient les feuilles `Produits` et `Tarifs`.

1. Lister les feuilles
2. Lire la feuille `Produits`
3. Nettoyer les noms de colonnes

Solution

Exercice 2.2 : Nettoyer un export messy [Difficulté: Intermédiaire]

Énoncé : Le fichier `objectifs.xlsx` contient 2 lignes d'entête et des montants au format texte.

1. Lire la feuille `Objectifs` en sautant 2 lignes
2. Convertir `objectif_ca` en numérique
3. Supprimer les lignes où `region` est vide

Solution

Exercice 2.3 : Passer d'un format large à tidy [Difficulté: Intermédiaire]

Énoncé : Vous avez des colonnes `jan_2025`, `fev_2025`, `mar_2025` dans `objectifs_wide`.

1. Transformer en format long avec `pivot_longer()`
2. Séparer la colonne mois/année
3. Créer une date du premier jour du mois

Solution

Module 3 : Requêtes avancées I

Exercice 3.1 : Jointures multi-tables [Difficulté: Intermédiaire]

Énoncé : Construire une table analytique en joignant :

- `ventes` avec `clients` via `client_id`
- puis avec `produits` via `produit_id`

Ne conserver que les colonnes utiles : date, region, segment, famille, quantite, prix_net.

Solution

Exercice 3.2 : Détecter les références absentes [Difficulté: Avancé]

Énoncé : Trouvez les `produit_id` présents dans les ventes mais absents du catalogue Excel.

Indice : Utilisez `anti_join()`.

Solution

Exercice 3.3 : Top 5 clients par région [Difficulté: Avancé]

Énoncé : Calculez le chiffre d'affaires par client et région, puis gardez les 5 meilleurs clients de chaque région.

Solution

Module 4 : Requêtes avancées II et automatisation

Exercice 4.1 : Calcul d'évolution mensuelle [Difficulté: Avancé]

Énoncé : Créez un indicateur d'évolution mensuelle du CA par région avec `lag()`.

1. Agréger le CA mensuel
2. Créer `ca_mois_prec` et `variation_pct`
3. Trier par région puis mois

Solution

Exercice 4.2 : Fonction d'extraction paramétrée [Difficulté: Avancé]

Énoncé : Écrire une fonction `extraire_kpi(con, date_debut, date_fin, region = NULL)` qui :

- Filtre les ventes sur la période
- Filtre la région si fournie
- Retourne CA, nombre de commandes, panier moyen

Solution

Exercice 4.3 : Import robuste multi-fichiers [Difficulté: Avancé]

Énoncé : Importez tous les fichiers `.xlsx` du dossier `exports/` et capturez les erreurs sans interrompre le traitement.

Solution

Mini-cas de fin de journée (30 min)

Mission : Livrer un extrait client pour l'équipe commerciale :

1. Top 20 clients de la région Ouest (3 derniers mois)
2. CA cumulé, nombre de commandes, panier moyen
3. Indicateur d'évolution vs mois précédent
4. Export CSV nommé `top_clients_ouest_YYYYMMDD.csv`

Critères de validation : pipeline lisible, contrôle minimum des données, extraction reproductible.